

# Séries temporelles enregistrées par un flotteur MERMAIDS dans le Pacifique: détection et filtrage automatique de signaux hydro-acoustiques de séismes.

Lidia Ejarque Bueno

Enzo Boulin

10/03/2024

## Résumé

Un groupe de flotteurs autonomes équipés d'hydrophones, connus sous l'acronyme MERMAID, surveille l'activité sismique mondiale depuis l'intérieur des océans. Les instruments sont programmés pour détecter et transmettre les conversions de pression acoustique provenant des arrivées des ondes sismiques P, utilisées en tomographie mantellique. Les instruments rapportent les sismogrammes dans les heures ou les jours suivant leur enregistrement via des satellites. Cependant, les flotteurs ne sont généralement pas récupérés. Cela s'est produit une fois et toute la mémoire a pu être lue. Nous avons donc hérité d'un ensemble de données uniques : un an de son enregistré à des fréquences comprises entre 0,1 et 20 Hz dans le Pacifique Sud autour de la Polynésie française par un flotteur MERMAID. De plus, 213 séismes ont été relevés à la main dans ces données et reliés à des séismes répertoriés. L'algorithme de détection présent dans les bouées n'a relevé que 10 de ces séismes, les autres ont été jugés de faible priorité. Nous avons mis au point différentes techniques de traitement du signal et de machine learning pour améliorer les performances de l'instrument.

## Remerciements

Avec l'aide précieuse de :

Karin Sigloch, Sébastien Bonnieux, Philippe Blanc, Sébastien Travadel.

# 1 Introduction

La tomographie sismique globale, c'est-à-dire l'imagerie de la structure tridimensionnelle de la vitesse des ondes à l'intérieur de la Terre, est limitée par la rareté des stations océaniques.

Les approches visant à atténuer ce problème comprennent l'installation d'hydrophones amarrés et de sismomètres au fond des océans. Les difficultés logistiques et les coûts élevés de l'installation et de la récupération des données de ces dispositifs font que ces méthodes ne sont pas viables pour combler de vastes lacunes dans l'océan avec une densité de stations suffisante pour la tomographie sismique. La réaffectation des fibres optiques de télécommunication du fond des océans à la détection acoustique distribuée pourrait permettre d'étendre la portée des réseaux sismiques existants. MERMAID (Mobile Earthquake Recording in Marine Areas by Independent Divers) est une alternative récente mieux établie.

Cet instrument robotique peu coûteux, facile à déployer et généralement non récupéré est capable de maintenir une profondeur constante dans l'océan, où il enregistre en permanence le champ de pression acoustique et signale de manière autonome les arrivées de formes d'ondes sismoacoustiques en temps quasi réel. Une combinaison d'algorithmes de déclenchement dans le domaine temporel et d'identification probabiliste dans le domaine des ondelettes, exécutés à bord, détermine les détections d'arrivées probables d'ondes P de séismes, ce qui provoque la remontée de MERMAID à la surface afin de signaler

les formes d'ondes enregistrées par satellite avant de reprendre sa mission.

Au cours de la dernière décennie, plusieurs générations d'instruments MERMAID ont recueilli des milliers de tremblements de terre pouvant être utilisés pour des études sismiques. Cependant, la majeure partie de ces enregistrements n'est jamais transmise et reste dans la mémoire de l'instrument qui, dans la troisième génération de MERMAID, contient 1 an de données. La mémoire tampon peut contenir des séismes non détectés et des bruits provenant de diverses sources terrestres, océaniques et biologiques.

Exceptionnellement, lors d'une croisière de l'expérience SPPIM (South Pacific Plume Imaging and Modeling) menée en août 2019, l'instrument P0023 de l'Université de Princeton a été récupéré et redéployé, ce qui a permis le rapatriement d'une série temporelle d'un an.

Un doctorant de l'université de Princeton, Sirawich Pipatprathanporn a entrepris de détecter à la main tous les séismes présents dans cette série temporelle (voir [1] pour plus de détails). Il a d'abord identifié toutes les arrivées possibles de séismes dans le tampon, puis les a mises en correspondance, dans la mesure du possible, avec des séismes connus provenant de la base de données Preliminary Determination of Epicenters (PDE) du National Earthquake Information Center (NEIC) de l'United States Geological Survey (USGS), accessible via le Data Management Center (DMC) de l'Incorporated Research Institutions for Seismology (IRIS). Au total, 213 arrivées d'ondes ont été mises en correspondance de cette manière. Seules

10 d’entre elles avaient déjà été transmises par MERMAID.

Notre étude vise à déterminer comment traiter efficacement le signal et à développer différents algorithmes de détection de séismes, plus efficaces que celui actuellement en place. Plus d’informations sur MERMAID et l’algorithme à bord [ici](#).

## 2 Données

### 2.1 Enregistrements

Nos données sont des enregistrements dans le domaine temporel de la pression acoustique acquise par MERMAID P0023 à une profondeur de stationnement de 1500m sous la surface de l’océan en Polynésie française Pacifique entre son premier déploiement le 13 septembre 2018 et sa récupération fortuite le 15 août 2019.

Leur fréquence d’échantillonnage est de 40 Hz, correspondant à une fréquence de Nyquist de 20 Hz. Entre les remontées en surface, qui prennent environ 22 heures aller-retour et pendant lesquelles l’enregistrement est interrompu, la série temporelle est continue à l’exception d’intervalles sporadiques d’ajustements de profondeur, qui interrompent l’acquisition des données pendant quelques minutes chacun.

MERMAID remonte à la surface dès qu’il estime qu’une arrivée d’onde P détectée est susceptible d’être utilisée pour la tomographie sismique, ce qui se produit en moyenne tous les 6-7 jours. À ce rythme de retour des données, la durée de vie d’un instrument

MERMAID fonctionnant avec un seul jeu de piles au lithium est d’environ 5 ans. Au moment de la transmission des données, la position et l’heure du système de positionnement global (GPS) sont obtenues et regroupées sous forme de métadonnées. L’horodatage GPS est utilisé pour corriger la dérive de l’horloge de l’instrument, généralement d’une fraction de seconde. Au cours de la période de 11 mois (environ 336 jours ou 8064 heures) dont il est question ici, MERMAID a fait surface 44 fois. Au total, nous disposons de 7029 heures de données, ce qui équivaut à 87% du temps de déploiement. Un exemple d’enregistrement est donné en figure 1

### 2.2 Séismes répertoriés

Nous disposons également d’une base de 213 séismes (grâce à [1]). Nous avons accès à différentes informations pour chacun des séismes, nous avons seulement utilisé :

- La date d’arrivée du séisme
- Sa catégorie (Tag)

En effet, il y a différentes catégories résumés dans ce tableau :

DET	Séisme détecté par MERMAID
REQ	Séisme réquisitionné par satellite
(***, **, *)	Onde P relevée à la main
(S3,S2,S1)	Onde de surface relevée à la main

Pour les séismes détectés à la main, les niveaux 1, 2, 3, vont des événements les moins remarquables aux plus remarquables (ratio signal/bruit plus élevé).




Figure 1: Exemple d'enregistrement MERMAID contenant un séisme

### 3 Traitement du signal

Le signal observé est très bruité (cf figure 1). Une première idée a été de regarder son spectre. On observe alors :




Figure 2: Spectre en fréquence d'un enregistrement

On voit alors que le bruit est localisé sur la bande de fréquence  $[0.1, 1]$ . La hauteur et la largeur de ces bosses varient en fonction des saisons mais ne font pas l'objet de notre étude (voir [1] pour plus d'informations). Le bruit en dessous de 0.05Hz est dû, au moins en partie, à la baisse de sensibilité du capteur.

A présent, observons le spectrogramme d'un signal contenant un séisme. En effet le spectre précédent étant effectué sur toute la durée du signal, la trace d'un éventuel séisme aurait été effacé par moyennage. Le spectrogramme évite ce phénomène.




Figure 3: Spectrogramme d'un séisme relevé à la main, le trait noir correspond à l'heure d'arrivée de l'onde P

On voit alors apparaître deux phénomènes récurrents dans la bande de fréquence  $[0.05, 0.1]$ . Tout d'abord un décrochage au moment de l'arrivée de l'onde P, ce décrochage correspond donc à sa signature fréquentielle. Puis une deuxième onde, plus longue et puissante qui s'atténue petit à petit: c'est l'onde de surface. Il apparaît donc que ce soit la bande de fréquence entre 0.05 Hz et 0.1 Hz qu'il faille regarder. Cela nous a paru très surprenant au début puisque l'algorithme à bord de MERMAID filtre en dessous de 2 Hz pour ne garder que les hautes fréquences. En effet au moment de la conception de l'algorithme MERMAID, aucun séisme n'avait été enregistré par des hydrophones, les concepteurs se sont donc inspirés des sismogrammes terrestres sur lequel les ondes P se détectent grâce aux fréquences supérieures à 2 Hz. En théorie, nous devrions

observer un décrochage marquant l'arrivée de l'onde P entre 0.05 Hz et 8 Hz, en pratique, on observe rarement le décrochage entre 1 Hz et 8 Hz et jamais celui entre 0.1 Hz et 1 Hz à cause du bruit. Par ailleurs, notons que sur le spectrogramme on retrouve bien les deux bosses de bruit entre 0.1 et 1 Hz de la figure 2.

Nous avons donc filtré nos signaux avec un filtre de Butterworth passe-bande d'ordre 3 et sous échantillonné d'un facteur 100 pour augmenter la rapidité de calcul. Ensuite puisque c'est l'énergie du signal dans cette bande qui nous intéresse, c'est pourquoi nous avons pris une moyenne glissante sur 150 secondes du carré du signal. Illustration de ce pré-traitement en figure 4.




Figure 4: Pré-traitement des données, de haut en bas: signal brut, signal filtré entre 0.05 et 0.1 Hz, carré du signal filtré moyenné sur 150 secondes.

Cette méthode permet de faire apparaître clairement les événements sismiques avec un signal positif qui varie moins que le signal initial et qui contient beaucoup moins de points.

très rares et la bouée a des contraintes énergétiques importantes elle ne doit remonter que si c'est vraiment nécessaire. On veut donc limiter au maximum les faux positifs.

## 4 Algorithmes de détection

L'enjeu de cette section est de trouver un algorithme capable de détecter les "pics" qui correspondent à des séismes comme ceux de la figure 4. Bien évidemment, ils ne sont pas toujours aussi remarquables que les 2 séismes présents sur la figure 4 et parfois il y a des pics mais il n'y a pas de séisme. Autres choses importantes les séismes sont des événements

### 4.1 Random forest sur la série temporelle

Notre première idée a été de faire une forêt aléatoire directement sur la série pré-traitée (celle en bas de la figure 4). En effet, c'est un modèle robuste que nous maîtrisons bien car nous avons beaucoup travaillé dessus. Il est simple à mettre en œuvre et de très mauvais résultats permettent de rejeter directe-

ment l'approche. Concrètement, nous avons d'abord créé des fenêtres de 2h (2880 points). Avec pour les étiquettes positives un séisme au milieu, et pour les étiquettes négatives que du bruit. Nous avons ainsi 120 étiquettes positives et 1600 étiquettes négatives. En effet, à la base nous avons 213 séismes mais certains n'avaient pas 1h de marge avant et après l'arrivée du séisme et nous avons exclu les séismes de catégorie \* et S1 car ils avaient des pics trop faibles et entraînaient des confusions avec le bruit. Pour augmenter le nombre d'étiquettes positives et rendre le modèle plus robuste, dans le sens où le séisme ne doit pas être forcément pile au milieu de la fenêtre de 2 heures pour être détecté, nous avons décalé chaque séisme d'un petit  $\Delta t$  pris sous loi normale de moyenne nulle et d'écart type  $\frac{1h}{1000}$ . Nous avons ainsi créé 800 étiquettes positives avec un séisme à  $1h + \Delta t$  dans la fenêtre. Concernant les principaux paramètres de la forêt: 50 arbres, chaque arbre à une profondeur maximale de 20. Les performances du modèle sont en figure 5 et dans le tableau 1.




Figure 5: Matrice de confusion (en %) du random forest avec un jeu de test de 10%

accuracy	0.95
precision	1.0
recall	0.8
f1-score	0.89
kappa	0.86

Table 1: performance du random forest avec un jeu de test de 10%

Ces résultats semblent très satisfaisants. Mais ils sont surestimés car en pratique un séisme est un événement très rare. Sur l'ensemble du disque dur:

- 132 fenêtres contiennent un séisme
- 6473 fenêtres ne contiennent pas de séisme

Donc la probabilité *à priori* de tomber sur une fenêtre de deux heures avec un séisme est inférieure à 0.1. Or l'algorithme a été entraîné sur des classes beaucoup moins déséquilibrées que ça et il y a toujours la contrainte de sobriété énergétique de limiter les faux positifs. Il faut donc changer le seuil de détection. En effet, jusqu'ici le random forest classe une série temporelle par un vote à la majorité entre tous les arbres binaires. On peut décider qu'une fenêtre est classée comme contenant un séisme si plus de 70% des arbres binaires pensent que c'est un séisme. De cette manière on limitera les faux positifs puisqu'on augmente notre exigence sur la qualité des séismes détectés. Pour affiner le modèle nous allons étudier l'effet de seuil sur trois mesures de performances:

- False Positive Rate : probabilité de fausse alarme

$$FPR = \frac{FP}{FP + TN} = \frac{FP}{N}$$

- True Positive Rate : probabilité de bonne alarme

$$TPR = \frac{TP}{TP + FN} = \frac{TP}{P}$$

- Précision : pourcentage d'alarmes justifiés

$$Precision = \frac{TP}{TP + FP}$$

Lorsque l'on trace ces mesures en fonction des seuils, c'est-à-dire le taux d'arbres minimum qui doivent classer la série temporelle comme séisme pour que la forêt classe la série temporelle comme séisme, on obtient la figure 6.




Figure 6: True Positive Rate, Précision, False négative rate, en fonction du seuil de précision

On voit alors sur la figure 6 que la probabilité de fausse alarme n'est pas très contraignante, ce qui est logique car la classe qui correspond au déclenchement de l'alarme (présence de séisme) était plus petite que l'autre, donc peu de chance de faire une fausse alarme. Puisqu'il ne nous reste plus que 2 mesures, on peut tracer l'une en fonction de l'autre et voir le seuil qui permet de s'approcher du point idéal (1,1) (précision de 1 et True Positive Rate de 1). Cette courbe s'appelle la courbe précision-recall (autre nom du True Positive Rate) elle est représentée en figure 7.




Figure 7: Courbe précision-recall, avec une carte de chaleur correspondant à la valeur du seuil



Après avoir affiné le seuil et avoir fait tourner l’algorithme en conditions “réelles” sur le disque dur, on obtient les résultats du tableau 2:

accuracy	0.95
precision	0.87
recall	0.7
f1-score	0.77
kappa	0.81

Table 2: performance du random forest sur le disque dur après avoir affiné le seuil

Ces résultats sont un peu plus faibles que les résultats initiaux mais c’était prévisible puisqu’on est ici en conditions réelles avec parfois des séismes qui ont été oubliés dans le disque dur, ou encore puisque les séismes sont beaucoup moins fréquents que lors de l’entraînement de l’algorithme. De plus, pour éviter à la bouée de remonter trop souvent on peut décider, par exemple, de ne remonter immédiatement que les séismes détectés avec un taux supérieur à 0.95 et remonter tous ceux entre 0.85 et 0.95 à ce moment la. L’avantage d’une remontée juste après la détection est d’être plus précis sur la localisation du séisme, toutefois la position peut être estimé par interpolation entre les différentes remontées.

## 4.2 Random forest allégé

Le modèle précédent comprend 2880 features très corrélées avec leurs voisines et si le modèle arrive à être performant avec un si petit jeu de test relativement à la taille

du modèle, c’est qu’on peut réduire la taille du modèle. Pour cela, nous avons commencé par regarder l’importance de chaque feature dans un modèle entraîné avec le séisme toujours pile au milieu de la fenêtre pour ainsi voir quel pas de temps le modèle regarde en priorité (cf figure 13).




Figure 8: Importance relative de chaque pas de temps dans le random forest, moyenné sur 100000 arbres, en rouge arrivée de l’onde P.

Nous avons alors été très surpris de voir que le modèle ne regarde quasiment que ce qu’il se passe dans les minutes qui suivent l’arrivée de l’onde P, or si l’on se réfère à la figure 3, c’est l’onde de surface qui arrive dans les minutes suivant l’onde P. C’est donc l’arrivée de cette onde qu’il suffit détecter. En effet l’onde de surface est plus intense que l’onde P et donc logiquement plus facile à détecter. Par exemple en figure 9, l’onde P n’est quasiment pas visible mais l’onde de surface est très visible.

Nous avons donc développé cette algorithme pour réduire la taille du modèle. On

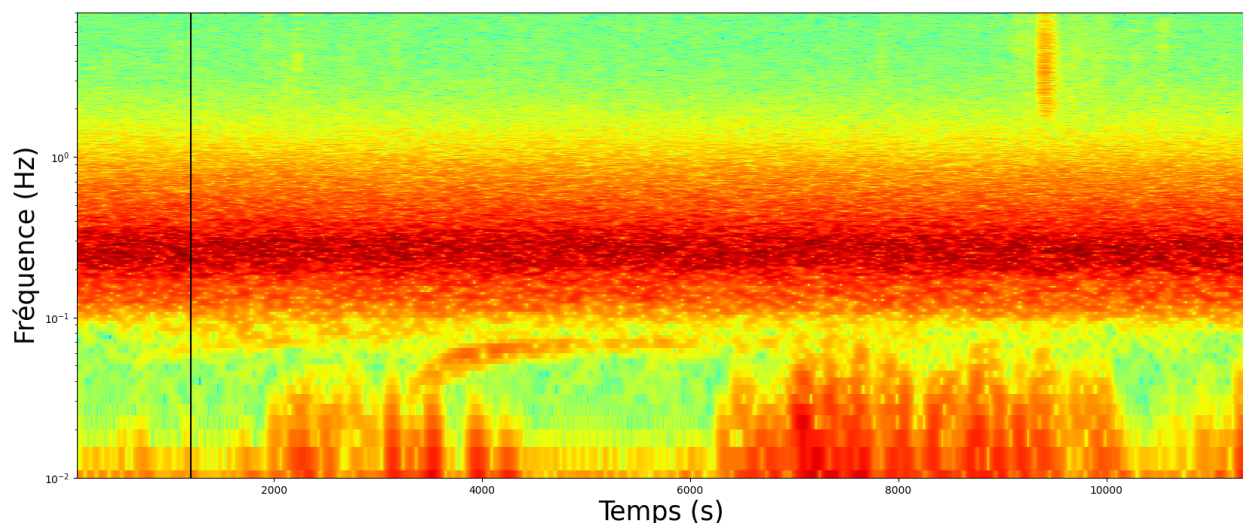


Figure 9: Spectrogramme d'un séisme \*, le trait noir correspond à l'heure d'arrivée de l'onde P, seule l'onde de surface est visible

prend le signal brut, on ne garde que la bande 0.05-0.1 Hz, on se place à l'arrivée de l'onde P puis on sépare le signal en 4 intervalles (les détails seront dans l'annexe). Les 4 features sont la moyenne de l'écart-type glissant sur ces 4 segments. Nous avons donc réduit notre modèle de 2880 à 4 features. Voilà les performances obtenues 3, 4.

	prédit positif	prédit négatif
vrai positif	17	7
vrai négatif	1	47

Table 3: Performances du random forest à 4 features

Les performances de cet algorithme sont assez similaires avec celle du premier avec de nombreux autres avantages. Tout d'abord le modèle étant petit il y a un risque de sur-apprentissage bien plus faible que dans

accuracy	0.88
precision	0.94
recall	0.71
f1-score	0.81
kappa	0.71

Table 4: Performances du random forest à 4 features

le premier cas. Ensuite ce programme est moins énergivore que le premier puisque plus léger. Enfin ce modèle n'est pas du tout optimisé car nous n'avons pas eu beaucoup de temps à y consacrer. Pour commencer il faudrait relever à la main ou bien à l'aide d'un modèle toutes les arrivées d'ondes du surface car dans ce modèle l'arrivée a été estimée grossièrement par rapport à l'arrivée de l'onde P et le delta de temps entre les deux arrivées varie beaucoup selon la distance qu'on

parcouru les ondes. Enfin nous n'avons pas testé beaucoup de traitement du signal pour cette méthode et une autre méthode que la moyenne de l'écart-type glissant pourrait être plus efficace.

### 4.3 STA/LTA sur les basses fréquences

Ce dernier algorithme ne fait appel à aucun modèle d'apprentissage automatique, il est donc plus fiable dans le sens où il n'y a pas de problème de sur-apprentissage ou de phénomène de "boîte noire". Il se base sur la même méthode que l'algorithme utilisé actuellement mais sur la bande de fréquence 0.05-0.1 Hz. Cet algorithme est beaucoup utilisé dans l'étude des signaux sismiques il consiste à faire une première moyenne glissante du signal au carré sur une "petite" fenêtre, short term average *STA*, et une autre moyenne glissante sur une "grande" fenêtre, long term average *LTA*, puis à afficher le ratio des 2, *STA/LTA*. A l'arrivée d'un séisme puisque la petite fenêtre est plus réactive que la grande le ratio va augmenter avant de diminuer lorsque la seconde fenêtre va réagir, pour plus de détail voir [2]. Pour cette méthode, nous avons choisi une première fenêtre de 1h40 et une seconde fenêtre de 4h. C'est un des premiers problèmes de cette méthode il faut de très longues fenêtres pour avoir des ratios suffisamment stables. En revanche cette méthode ne demande pas de connaître le futur pour être exécutée, on peut remonter MERMAID dès que le seuil est dépassé, contrairement aux random forest qui

nécessitent 1h de décalage pour fonctionner. Un premier exemple pour cette méthode est donné en figure 10. La méthode semble bien fonctionner, elle permet de mettre en lumière des événements oubliés, comme les autres méthodes, elle bute sur les séismes de faibles amplitudes qui ne dépassent pas le seuil. Elle a l'avantage d'être très économique car les convolutions ne requièrent pas une grande puissance de calcul. Nous avons eu de mal à analyser quantitativement les performances de cette méthode. Cette méthode présente l'avantage de pouvoir estimer la durée du signal en enregistrant le moment où le ratio repasse en dessous de la moyenne (cf figure 11). Les résultats de cette méthode sont très satisfaisants bien qu'il rate encore de nombreux séismes de faible amplitude.

### 4.4 Réseau de neurones sur les images des spectrogrammes

Comme on a vu précédemment, les spectrogrammes révèlent d'une façon très claire les événements qui nous intéressent : l'arrivée de l'onde P, et un peu plus tard, l'onde de surface. Ces deux événements sont observables dans la bande de fréquence 0.05-0.1 Hz.

On a donc généré 2400 spectrogrammes, 1600 spectrogrammes avec du bruit, et 800 spectrogrammes avec des séismes (de type 1, 2 et 3 étoiles). Ce réseau de neurones convolutif (CNN) est destiné à la classification binaire grâce aux images des spectrogrammes: le but étant d'identifier si le spectrogramme comporte ou pas un séisme. Le premier CNN qu'on a fait comportait deux




Figure 10: Analyse STA/LTA sur une série temporelle entière, le seuil de détection est en rouge, les séismes connus en vert




Figure 11: Analyse STA/LTA sur un séisme, le seuil de détection est en rouge, l'arrivée de l'onde P en vert, on peut estimer la durée du séisme comme la durée entre les intersection du seuil avec la courbe STA/LTA

couches de convolution et de deux couches de max pooling pour extraire les caractéristiques importantes des données d'entrée. Ensuite, les données sont aplaties avant de passer à travers deux couches entièrement connectées. Une fonction ReLU est utilisée pour introduire de la non-linéarité, tandis qu'une activation Softmax produit les probabilités normalisées pour chaque classe. Ce premier CNN avait environ 25 million de paramètres, donc on a enlevé une couche de convolution, et encore changé quelques hyperparamètres. Avec ces changements on est passés à environ 2 millions de paramètres, mais l'accuracy n'a pas beaucoup évolué. On obtenait environ 0.7 d'accuracy, mais la loss évoluait de façon étrange, en diminuant au début, puis en réaugmentant.




Figure 12: Couches de convolution d'un réseau de neurones qui permettrait de classifier les séismes.

Comme l'algorithme de random forest était très performant pour les séismes deux et trois étoiles mais pas autant pour les séismes une étoile, on s'est donc demandé si la méthode

CNN pouvait remplir cette lacune de la méthode Random Forest. Malheureusement, la CNN continuait à ne pas être très efficace. On a également essayé de réduire les données à juste la bande de fréquence entre 0.05 et 0.1 Hz, mais elle avait encore des plus mauvaises performances. Par ailleurs, on a regardé les couches de convolution, qui ressemblent à ce que montre l'image à droite. On a l'impression qu'on ne voit presque pas l'évènement, ce qui est peut-être une des causes de la faillite de cette algorithmne.

En aillant toujours comme objectif de détecter les séismes non détectables par l'algorithme Random Forest, on a également effectué une autre analyse en visualisant les pics créés par la différence d'énergie quand l'onde P arrive, et quand elle n'est pas présente. Cette méthode ressemble beaucoup à une STA/LTA, et le but serait également de détecter le pic. Dans des cas (même pour des séismes 1 étoile), elle est très efficace, mais dans d'autres ce n'est pas très satisfaisant...




Figure 13: Pic de puissance d'un séisme 1 étoile.




Figure 14: Spectrogramme sur la gamme de fréquence 0.05-0.1 Hz, puis spectrogramme sur toute la bande de fréquence

## 5 Conclusion

Notre étude a montré que les performances de détections d'évènements sismiques des bouées MERMAIDS pouvaient être significativement améliorées en regardant la bande de fréquence  $[0.05, 0.1]$  Hz plutôt que  $[2, 8]$  Hz. Pour cela, nous avons mis en place différents algorithmes de détection: deux random forest, CNN et STA/LTA. Le temps qui nous était imparti (3 mois) ne nous a pas permis d'évaluer avec suffisamment de précision les différents modèles pour en distinguer un particulièrement efficace par rapport aux autres. Nous avons également montré qu'il est essentiel de regarder les ondes de surface pour détecter les séismes de faible amplitude. Malgré tout, ces algorithmes restent moins efficaces qu'un opérateur humain regardant le spectrogramme ou bien écoutant les séismes, ainsi les séismes de très faible amplitude (classe \* et S1) sont rarement détectés par nos algorithmes.

## 6 Perspectives

Pour la suite de ce projet, il serait intéressant de poursuivre le random forest "allégé" en essayant de trouver les dates d'arrivée des ondes de surface, soit manuellement, soit à l'aide d'un modèle physique à partir de l'arrivée des ondes P. Il faudra ensuite choisir la manière optimale de découper les intervalles après l'arrivée de l'onde de surface et de les traiter. Ainsi l'algorithme sera entraîné sur des étiquettes plus précises. Une autre piste serait de continuer l'algorithme

STA/LTA en essayant d'ajuster le seuil et la durée des fenêtres glissantes pour obtenir un algorithme robuste sans risque de biais puisqu'il ne nécessite pas d'entraînement. Enfin, il pourrait être intéressant d'étudier le bruit plus en détail afin de comprendre comment le supprimer puisqu'une partie du signal sismique est perdue dans cette bande de fréquence. Par ailleurs, il serait intéressant d'essayer de voir s'il y aurait d'autres moyens d'analyser les spectrogrammes pour rendre compte des séismes. Par exemple, utiliser un algorithme YOLO pour labelliser les séismes pourrait être très intéressant, ainsi que trouver d'autres moyens pour faire parler ces images qui, à l'oeil nu, nous parlent autant.

## Références

1. Sirawich Pipatprathanporn, Frederik J Simons, *One year of sound recorded by a MERMAID float in the Pacific: hydroacoustic earthquake signals and infrasonic ambient noise*, Geophysical Journal International, Volume 228, Issue 1, January 2022, Pages 193–212
2. Allen, R. V. (1978), *Automatic earthquake recognition and timing from single traces*, Bull. Seismol. Soc. Am., 68(5), 1521–1532.
3. Sukhovich, A., J.-O. Irisson, F. J. Simons, A. Ogé, Y. Hello, A. Deschamps, and G. Nolet (2011), *Automatic discrimination of underwater acoustic signals generated by teleseismic P-waves*:

- A probabilistic approach*, Geophys. Res. Lett., 38, L18605,
4. A. Douglas; *Bandpass filtering to reduce noise on seismograms: Is there a better way?*. Bulletin of the Seismological Society of America 1997; 87 (3): 770–777.
  5. A. Sukhovich *et al.* What is MERMAID?